

## LDA & QDA

1. 数学角度剖析（贝叶斯）
2. 一维的 LDA
3. 多维的 LDA
4. QDA
5. 非数学角度解释
6. Logistics Regression, LDA, QDA 对比
7. 分类器评估

## LDA / QDA 详细整理

### ★ 数统角度剖析

记得 Logistic Regression 用 sigmoid function 直接估计  $P(Y=k|X=x; \theta) = \frac{1}{1+e^{-\theta x}}$   
现在考虑一种间接的方式来估计。

记得贝叶斯公式:

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_j P(B|A_j)P(A_j)}$$

其中  $P(A_i)$  是先验概率, 因为它不需考虑 B 方面的因素。

在这里,  $P(A_i) \Rightarrow P(Y=k) \Leftrightarrow \pi_k$

$\pi_k$  代表一个随机抽样是来自第 k 类的先验概率

(一共 10000 个样本, 6000 个属于 A 类, 3000 个 B 类, 1000 个 C 类,

那么  $\pi_A = \frac{6000}{10000} = 0.6$ ,  $\pi_B = 0.3$ ,  $\pi_C = 0.1$ )

而  $P(B|A_i) \Rightarrow P(X=x|Y=k) \Leftrightarrow f_k(x)$

$f_k(x)$  表示, 在对应的每个类别的情况下, 相应的 X 的分布

(已知选定 A 类,  $P(X|Y=A)$  代表 6000 个 sample 的分布)

$\Leftrightarrow$  the density function of X for an observation that comes from the kth class.

$\Leftrightarrow f_k(x)$  is relatively large if there is a high probability that an observation in the kth class has  $X \approx x$

综上:

$$P(Y=k|X=x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}$$

估计或计算  $\pi_k$  很简单, 而估计  $f_k(x)$  很难. 除非我们用一些简单的分布代替.

★首先, LDA for  $P=1$  (we only have 1 predictor)

假设  $f_k(x)$  是 normal distribution.

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2\sigma_k^2}(x-\mu_k)^2\right)$$

where  $\mu_k, \sigma_k^2$  are the mean and variance for  $k$ -th class.

这里, 假设  $\sigma_1^2 = \dots = \sigma_k^2$

那么

$$P_k(x) = P(Y=k|X=x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu_k)^2\right)}{\sum_{i=1}^K \pi_i \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu_i)^2\right)} \quad *$$

The Bayes classifier involves assigning an observation  $X=x$  to the class for which  $*$  is largest.

在对  $*$  作对数变换和整理后:

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$


举例: if  $K=2, \pi_1=\pi_2$

$$\Rightarrow \delta_1(x) = x \cdot \frac{\mu_1}{\sigma^2} - \frac{\mu_1^2}{2\sigma^2} + \log(\pi_1)$$

$$\delta_2(x) = x \cdot \frac{\mu_2}{\sigma^2} - \frac{\mu_2^2}{2\sigma^2} + \log(\pi_2)$$

如果  $\delta_1(x) > \delta_2(x)$ , 则为 class 1.  $\Leftrightarrow 2x(\mu_1 - \mu_2) > \mu_1^2 - \mu_2^2$

$$\text{那么, Decision Boundary} \Rightarrow x = \frac{\mu_1^2 - \mu_2^2}{2(\mu_1 - \mu_2)} = \frac{\mu_1 + \mu_2}{2}$$



但真实情况下,  $f_k(x)$  不一定是 Gaussian, 就算是 Gaussian,  $\mu_1, \dots, \mu_k, \sigma_1^2, \dots, \sigma_k^2$  (这里都是  $\sigma^2$ ),  $\pi_1, \dots, \pi_k$ , 都要估计.



但是 LDA 对 Bayes classifier 通过以下方式估计.

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i: y_i=k} x_i$$

$$\hat{\sigma}^2 = \frac{1}{n-k} \sum_{k=1}^K \sum_{i: y_i=k} (x_i - \hat{\mu}_k)^2$$

其中,  $n_k$  是在  $k$  类中的所有样本数,  $\hat{\mu}_k$  就是  $k$  类中样本均值  
 $\hat{\sigma}^2$  看作是各个类的样本方差的加权平均.

$$\text{而 } \hat{\pi}_k = n_k/n. \quad (n \text{ 为样本总数})$$

把这些 estimates 带到  $\delta_k(x)$  中

$$\Rightarrow \hat{\delta}_k(x) = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k)$$

对于一个 observation, ~~把它算~~ 把它归到使  $\hat{\delta}_k(x)$  最大的那类.

LDA 中的 L  $\Rightarrow$  linear 意思是  $\delta_k(x)$  是  $x$  的线性方程.

★ 接下来,  $p > 1$  的时候呢?

$\Rightarrow X = (X_1, X_2, \dots, X_p)$  is drawn from a multi-variate Gaussian Distribution, with a class-specific mean vector and a common cov matrix.

Multivariate Gaussian 假设每一个 predictor ( $X_i$ ) 都服从一维的 Gaussian. 其中每对 predictor ( $[X_i, X_j]$ ) 有相关性.

To indicate that a  $p$ -dimensional random variable  $X$  has a multivariate Gaussian distribution, we write  $X \sim N(\mu, \Sigma)$   $\mu = E(X)$ ,  $\Sigma = \text{Cov}(X)$ .

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)\right)$$

同理作一些处理之后

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

使得, 对于一个给定的 observation, 我们把它归到使  $\delta_k(x)$  最大的类

示意图如下

dash lines 代表 ~~是~~ decision boundary, 或者说

它们代表满足  $\delta_k(x) = \delta_l(x)$  ( $k \neq l$ )

同样我们也要估计  $\mu_1, \dots, \mu_k, \pi_1, \dots, \pi_k, \Sigma$ 。

对于实际应用来说, LDA 所得到的分类结果, 往往 ~~没有~~ 有 lowest total error out of all classes  $\Rightarrow$  Sensitivity / Specificity 会很低

这种情况下, 要适应调整 threshold, 来提高对某个类别的分类准确度. (怎么选 threshold? Grid search)

**BONUS:** How to evaluate a classification model performance?

- ① ROC 是一种检验方法  $\Rightarrow$  ROC traces out two types of error as we vary the threshold value.
- ② confusion matrix  $\Rightarrow$  提炼多个指标. (sensitivity, specificity, recall, accuracy ...)
- ③ 调整 threshold, 上面说过
- ④ AUC, 其实就是 ROC 曲线下面的面积.



# ★ QDA $\Rightarrow$ Quadratic Discriminant Analysis

比较:

	LDA	QDA	( $P=2$ )
(1)	$S_k(x)$ 是 $x$ 的线性函数	$\sim$ 二次函数	
(2)	$\sigma^2 / \Sigma$ 是一样的	$\sim$ 不一样	$\Downarrow$ 一个意思
(3)	$X \sim N(\mu_k, \Sigma)$	$X \sim N(\mu_k, \Sigma_k)$	
(4)	decision boundary 线性	$\sim$ 非线性	

QDA 中的  $f_k(x)$  在  $\log$  变换后

$$\begin{aligned} \Rightarrow S_k(x) &= -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \\ &= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \end{aligned}$$

Quadratic

??? 所以为什么  $\Sigma \rightarrow \Sigma_k$  是很重要的?

$\Rightarrow$  Bias - variance ~~trade~~ trade-off

在  $\Sigma$  不一样时, QDA 在对  $\Sigma$  求解时, 要很大计算量, 所以 LDA 要比 QDA less flexible (甚至它们的复杂度差别较大)

??? 所以, 什么时候用 LDA / QDA?

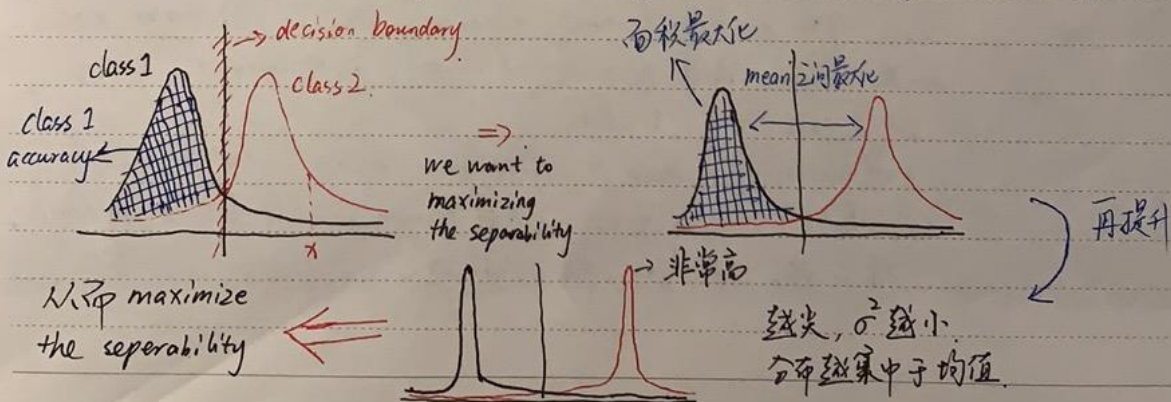
training set is very large  $\rightarrow$  QDA

relatively small  $\rightarrow$  LDA (避免 overfitting)

★ 下面我们从非数学角度, 通俗来讲解一下 LDA, QDA

(QDA)

LDA  $\Rightarrow$  maximizing the separability between the two/multi groups



也就是要  $\max \frac{(u_1 - u_2)^2}{S_1^2 + S_2^2} \rightarrow \frac{\text{ideally large}}{\text{ideally small}}$

这里的 1, 2 代表类别。  
(和 PCA 很像, 目的是 project data on lower dimension to maximize separation)

★ 最后, 把 Logistic Regression, LDA, QDA 进行对比。

Q&A:

Q1: 既然 Logistic Regression 不错, why LDA?

A1: 1) 当类别是 well-separated (没有或很少 overlapping), LR 不稳定  
2) 当  $n$  小,  $f(X=x)$  是 normally distributed, LDA 更稳定  
3) LR 很难处理 multi-classification.

Q2: Logistic Regression 和 LDA 有什么相似么?

A2: 注意: 对于 LR,  $h_\theta(x) = \frac{1}{1+e^{-\theta^T x}} \Rightarrow \log\left(\frac{p_i}{1-p_i}\right) = \theta^T x$  可理解为  $(\beta_0 + \beta_1 x)$   
这里  $p_i = h_\theta(x) = P(Y=k | X=x; \theta)$   
 $\frac{p_i}{1-p_i} \Rightarrow \text{odds}$

对于 LDA:  $\log\left(\frac{p_i}{1-p_i}\right) = C_0 + C_1 x$ , 其中  $C_0, C_1$  都是  $\mu_1, \mu_2, \sigma^2$  的函数 (不推导了)

可看出 LR 和 LDA 的 decision boundary 都是线性的。

只不过  $\beta_0, \beta_1$  通过 MLE 估计的,  $C_0, C_1$  通过估计  $\mu_1, \mu_2, \sigma^2$ 。

Q3: 它们何时使用?

A3: 首先, 可以对每个 feature (numerical) 做一个 distribution plot, 如果 feature 满足 normally distributed, 且 training set 不大, LDA 更好。否则 LR 更好。

(如果 decision boundary 是 highly non-linear, KNN 是不错的选择)  
QDA 是介于它们之间的, 它的 decision boundary 是 quadratic。  
实操的话, 10-fold CV 大法好!

## LDA/QDA example

Zijing Gao

4/21/2020

```
# Load the data
library(ISLR)

# train test split
train_idx = sample(nrow(iris), 0.8*nrow(iris))
train = iris[train_idx,]
test = iris[-train_idx,]

library(MASS)

lda.fit = lda(Species~., data = train)

cbind(prior = lda.fit$prior,
      counts = lda.fit$counts)

##              prior counts
## setosa      0.3416667    41
## versicolor 0.3166667    38
## virginica   0.3416667    41

prop = lda.fit$svd^2/sum(lda.fit$svd^2)
prop

## [1] 0.990934147 0.009065853
```

We can use the singular values to compute the amount of the between-group variance that is explained by each linear discriminant. In our example we see that the first linear discriminant explains more than 99% of the between-group variance in the iris dataset.

```
# predict with test data
pred.lda = predict(lda.fit, test[,1:4])
table(pred.lda$class, test$Species)

##
##          setosa versicolor virginica
## setosa          9           0         0
## versicolor      0          12         0
## virginica       0           0         9
```

Perfect!

```
# set CV = TRUE
lda.cv = lda(Species~., data = iris, CV = TRUE)
table(lda.cv$class, iris$Species)
```



```
##
##          setosa versicolor virginica
## setosa          50           0         0
## versicolor       0          48         1
## virginica        0           2        49

cat("accuracy:", sum(diag(table(lda.cv$class, iris$Species))) / sum(table(lda.cv$class, iris$Species)))

## accuracy: 0.98

qda.fit = qda(Species~., data = train)
pred.qda = predict(qda.fit, test[,1:4])
table(pred.qda$class, test$Species)

##
##          setosa versicolor virginica
## setosa          9           0         0
## versicolor       0          12         0
## virginica        0           0         9

qda.cv = qda(Species~., data = iris, CV = TRUE)
table(qda.cv$class, iris$Species)

##
##          setosa versicolor virginica
## setosa          50           0         0
## versicolor       0          47         1
## virginica        0           3        49

cat("accuracy:", sum(diag(table(qda.cv$class, iris$Species))) / sum(table(qda.cv$class, iris$Species)))

## accuracy: 0.9733333
```